

مراحل طراحی و توسعه یک سیستم بینایی ماشین

دوره آموزشی: از پردازش پیکسل تا هوش بصری عمیق
تاریخ گزارش: ۲۸ خرداد تا ۱۶ تیر ۱۴۰۴

👤 مدرس: جناب آقای محسن دارچینی تبریزی
👤 نگارنده: سیدعرفان مسعودی

@erfanmasoudiba

erfanmasoudiba@gmail.com

linkedin.com/in/erfan-masoudi github.com/ErfanMasoudiBA

فهرست مطالب

۲	۱ گام اول: تعریف مسئله
۳	۲ گام دوم: تحلیل نیازمندی‌ها
۴	۳ گام سوم: جمع‌آوری داده
۵	۴ گام چهارم: طراحی و برچسب‌گذاری داده
۶	۵ گام پنجم: پیش‌پردازش داده
۷	۶ گام ششم: انتخاب رویکرد و مدل
۹	۷ گام هفتم: آموزش مدل
۱۱	۸ گام هشتم: ارزیابی مدل
۱۳	۹ گام نهم: بهبود و بهینه‌سازی
۱۴	۱۰ گام دهم: اعتبارسنجی نهایی
۱۵	۱۱ گام یازدهم: استقرار سیستم
۱۷	۱۲ گام دوازدهم: پایش و مانیتورینگ
۱۸	۱۳ گام سیزدهم: بازآموزی و بروزرسانی
۱۹	۱۴ گام چهاردهم: ملاحظات اخلاقی و قانونی
۲۰	۱۵ منابع

۱. گام اول: تعریف مسئله

◀ مشکل یا نیاز اصلی چیست؟

بر اساس آمارهای سازمان بهداشت جهانی (WHO) در سال ۲۰۲۲، سرطان کبد یکی از عوامل اصلی مرگ و میر ناشی از سرطان در جهان به شمار می‌رود. تشخیص زودهنگام، تعیین دقیق حجم و مرزبندی تومورها نقش حیاتی در برنامه‌ریزی‌های درمانی و جراحی ایفا می‌کند. با این حال، بررسی دستی تصاویر پزشکی توسط رادیولوژیست‌ها فرآیندی بسیار زمان‌بر، خسته‌کننده و مستعد خطای انسانی (به ویژه در تفسیر مرزهای مبهم) است؛ بنابراین نیاز مبرمی به یک سیستم خودکار و دقیق وجود دارد.

◀ چرا بینایی ماشین برای حل آن مناسب است؟

بینایی ماشین و به‌طور خاص مدل‌های یادگیری عمیق، توانایی بالایی در استخراج ویژگی‌های پیچیده و الگوهای بافتی غیرخطی از تصاویر پزشکی دارند. این سیستم‌ها می‌توانند چالش‌های سنتی پردازش تصویر در داده‌های سی‌تی اسکن (مانند کنتراست پایین بین کبد و بافت‌های نرم مجاور و همچنین تنوع شدید در شکل، اندازه و موقعیت تومورها) را با دقت و تکرارپذیری بالا حل کنند.

◀ هدف نهایی و خروجی مورد انتظار چیست؟

هدف این پروژه، توسعه یک سیستم هوش مصنوعی مبتنی بر شبکه‌های عصبی عمیق با الگوبرداری از معماری UNet++ جهت بخش‌بندی (Segmentation) خودکار بافت کبد و تومورهای کبدی در تصاویر Scan CT است. خروجی مورد انتظار این سیستم، تولید ماسک‌های دقیق پیکسل‌به‌پیکسل از نواحی هدف است که عملکرد آن در نهایت با معیارهای استاندارد تصویربرداری پزشکی، به ویژه ضریب شباهت دایس (DSC) - Coefficient Similarity (Dice مورد ارزیابی قرار می‌گیرد.

۲ ≡ گام دوم: تحلیل نیازمندی‌ها

◀ کاربران و ذینفعان سیستم چه کسانی هستند؟

کاربران اصلی این سیستم، رادیولوژیست‌ها و پزشکان متخصص آنکولوژی هستند که می‌توانند از آن به‌عنوان یک دستیار هوشمند برای افزایش سرعت و دقت تشخیص بهره ببرند. علاوه بر این، بیماران نیز به‌صورت غیرمستقیم از تشخیص زودهنگام تومورها، کاهش خطای انسانی و جلوگیری از تشخیص‌های مثبت کاذب منتفع خواهند شد.

◀ دسترسی به داده‌ها و منابع چگونه است؟

مهم‌ترین چالش در این بخش، حفظ حریم خصوصی بیماران است که دسترسی آزاد به تصاویر پزشکی را محدود می‌کند. از سوی دیگر، داده‌های موجود معمولاً در قالب‌های مختلف ذخیره شده‌اند و پیش از ورود به مدل، نیازمند استانداردسازی، یکپارچه‌سازی فرمت و آماده‌سازی ساختاری هستند. بنابراین کیفیت و سازمان‌دهی داده‌ها نقش تعیین‌کننده‌ای در موفقیت پروژه دارد.

◀ محدودیت‌های فنی، مالی، زیرساختی و زمانی چیست؟

از منظر فنی، تصاویر پزشکی معمولاً به‌صورت سه‌بعدی و در فرمت‌هایی مانند NIfTI ذخیره می‌شوند و پردازش آن‌ها به منابع سخت‌افزاری قدرتمند، به‌ویژه RAM و GPU بالا، نیاز دارد. در نتیجه، استفاده از روش‌هایی مانند پردازش قطعه‌به‌قطعه (Patch-based) برای مدیریت بار محاسباتی ضروری است. همچنین، داده‌های Scan CT بر حسب واحد HU مقداردهی می‌شوند و پیاده‌سازی صحیح تکنیک Windowing برای استخراج بازه مناسب بافت کبد، یک چالش فنی مهم به‌شمار می‌رود. از نظر زمانی نیز، به دلیل حساسیت بالای کاربردهای پزشکی و نیاز به اعتبارسنجی‌های تخصصی و قانونی، چرخه توسعه چنین سامانه‌ای بسیار طولانی‌تر از پروژه‌های معمول پردازش تصویر است و ممکن است از مرحله ایده تا استقرار بالینی حدود ۱ تا ۳ سال زمان ببرد.

۳ گام سوم: جمع‌آوری داده

چه نوع داده‌هایی لازم است؟

داده‌های مورد نیاز این پروژه شامل دو بخش اصلی است: نخست، داده خام یعنی اسکن‌های سه‌بعدی توموگرافی کامپیوتری (CT) (Scan) از ناحیه شکم که ترجیحاً در فاز وریدی (Portal) Venous (Phase) ثبت شده‌اند؛ زیرا در این فاز، اختلاف کنتراست میان بافت سالم کبد و ضایعات تومورال بیشینه می‌شود. این داده‌ها به صورت حجم‌های سه‌بعدی و در قالب فرمت NIfTI (.nii) برای ورود به مدل پردازش می‌شوند. دوم، برچسب‌های مرجع (Ground Truth) شامل ماسک‌های سه‌بعدی متناظر با هر اسکن است که توسط رادیولوژیست‌های متخصص به صورت دستی حاشیه‌نویسی شده‌اند. این ماسک‌ها معمولاً سه کلاس را شامل می‌شوند: پس‌زمینه (کد ۰)، بافت سالم کبد (کد ۱) و تومور (کد ۲).

منابع داده کدام‌اند؟

منبع اصلی و بهینه برای این مرحله، دیتاست‌های استاندارد و اعتبارسنجی‌شده جهانی مانند Liver LiTS Segmentation Tumor (Benchmark) است که از طریق پلتفرم‌هایی نظیر Kaggle نیز در دسترس قرار دارد. این داده‌ها از دستگاه‌ها و پروتکل‌های تصویربرداری بیمارستان‌های مختلف گردآوری شده‌اند و همین تنوع، نقش مهمی در کاهش بیش‌برازش (Overfitting) و افزایش توان تعمیم‌پذیری مدل نهایی دارد.

ملاحظات حریم خصوصی و قانونی چیست؟

پردازش تصاویر پزشکی مستقیماً با قوانین سخت‌گیرانه حفاظت از داده‌های سلامت، مانند HIPAA و GDPR، در ارتباط است. مهم‌ترین الزام در این بخش، بی‌نام‌سازی کامل (Anonymization) / (De-identification) داده‌ها است. فایل‌های پزشکی در قالب اصلی خود، یعنی DICOM، شامل هدرهایی دارای اطلاعات هویتی حساس بیمار (PHI) مانند نام، تاریخ تولد و کد ملی هستند. بنابراین، پاک‌سازی کامل این متادیتاها و تبدیل ایمن داده‌ها به فرمت NIfTI پیش از ورود به فرآیند آموزش مدل، یک الزام قانونی و اخلاقی غیرقابل مذاکره محسوب می‌شود.

۴ گام چهارم: طراحی و برچسب‌گذاری داده

داده‌ها چگونه ساختاردهی و سازمان‌دهی می‌شوند؟

تصاویر سه‌بعدی Scan CT به‌عنوان ورودی سامانه سازمان‌دهی می‌شوند و خروجی‌ها نیز در قالب ماسک‌های سه‌کلاسه استاندارد ساختار می‌یابند: پس‌زمینه با کد ۰، بافت سالم کبد با کد ۱ و تومور با کد ۲. این ساختار یکپارچه، امکان آموزش دقیق و ارزیابی منسجم مدل را فراهم می‌کند.

برچسب‌گذاری چگونه انجام می‌شود؟

فرآیند برچسب‌گذاری باید توسط رادیولوژیست‌های مجرب و با استفاده از نرم‌افزارهای تخصصی مانند ITK-SNAP به‌صورت دستی و مقطع‌به‌مقطع (Slice-wise) روی تصاویر سه‌بعدی انجام شود. این روش، دقت مرزبندی ضایعات و کیفیت Ground Truth را به‌طور قابل‌توجهی افزایش می‌دهد.

کیفیت و تنوع داده‌ها چگونه تضمین می‌شود؟

برای جلوگیری از بیش‌برازش (Overfitting) نسبت به تنظیمات یک دستگاه یا یک مرکز درمانی خاص، داده‌ها به‌صورت چندمرکزی (Multi-center) از بیمارستان‌ها و اسکنرهای مختلف جمع‌آوری می‌شوند تا مدل در مواجهه با شرایط متنوع تصویربرداری، تعمیم‌پذیری بالاتری داشته باشد. همچنین برای کاهش خطای انسانی، از یک پروتکل بازبینی چندمرحله‌ای استفاده می‌شود؛ به این صورت که برچسب‌های اولیه توسط یک رادیولوژیست ثبت شده و سپس توسط چند متخصص دیگر به‌صورت مستقل بررسی و تأیید می‌شوند. در صورت وجود اختلاف نظر، تصمیم نهایی بر اساس نظر پزشک ارشد اتخاذ می‌شود.

۵ ⚙️ گام پنجم: پیش‌پردازش داده

➤ پاک‌سازی داده‌ها

نویز در تصاویر سی‌تی اسکن شامل بافت‌های غیرهدف و نامربوط مانند هوای اطراف بیمار، تخت دستگاه و استخوان‌ها است. پاک‌سازی این موارد با استفاده از تکنیک پنجره‌بندی (Windowing) و محدود کردن مقادیر هانسفیلد (HU) به بازه بافت نرم شکم (مثلاً بین ۱۰۰- تا ۲۵۰) انجام می‌شود. همچنین، فایل‌های تصویری که دارای آرتیفکت‌های فلزی شدید (مانند اثر پلاتین در بدن بیمار) هستند، به دلیل تخریب کیفیت تصویر، از چرخه آموزش حذف می‌شوند.

➤ تغییر اندازه، نرمال‌سازی و اصلاح نور

در تصاویر پزشکی، شدت پیکسل‌ها نشان‌دهنده چگالی بافت‌ها (HU) است. جهت بهبود و پایداری فرآیند بهینه‌سازی گرادیان کاهشی (Gradient Descent)، پیکسل‌ها با استفاده از روش‌هایی مانند مقیاس‌گذاری کمینه-بیشینه (Min-Max Scaling) به بازه $[0, 1]$ یا $[-1, 1]$ نرمال‌سازی می‌شوند. از نظر ابعادی نیز مقاطع اسکن معمولاً دارای اندازه 512×512 هستند که به دلیل محدودیت‌های حافظه گرافیکی (VRAM)، یا به ابعاد کوچک‌تر (مانند 256×256) تغییر اندازه داده می‌شوند و یا به صورت قطعات کوچک‌تر (Patch-based) استخراج و به مدل تغذیه می‌گردند.

➤ تقسیم داده‌ها به مجموعه‌های آموزش، اعتبارسنجی و آزمون

داده‌ها با نسبت استاندارد (به عنوان نمونه ۷۰٪ آموزش، ۱۵٪ اعتبارسنجی و ۱۵٪ آزمون) تقسیم‌بندی می‌شوند. نکته حیاتی برای جلوگیری از بروز پدیده نشت داده (Data Leakage)، انجام این تقسیم‌بندی در سطح بیمار (Patient-level) است و نه در سطح مقاطع (Slices). تقسیم بر اساس مقطع باعث می‌شود تصاویر مختلف از یک بیمار هم‌زمان در مجموعه‌های آموزش و آزمون قرار گیرند که این امر منجر به ارزیابی غیرواقعی و بیش‌ازحد خوش‌بینانه از کارایی مدل خواهد شد.


۶ گام ششم: انتخاب رویکرد و مدل

◀ انتخاب نوع مدل

رویکرد مناسب برای این مسئله، یادگیری عمیق (Deep Learning) است. روش‌های کلاسیک پردازش تصویر، مانند آستانه‌گذاری (Thresholding) و نیز الگوریتم‌های سنتی یادگیری ماشین، توانایی کافی برای مدل‌سازی الگوهای پیچیده، سه‌بعدی و غیرخطی موجود در بافت‌های نرم و مرزهای مبهم تومورها در تصاویر CT را ندارند. در مقابل، شبکه‌های عمیق می‌توانند ویژگی‌های سطح پایین و سطح بالا را به صورت خودکار استخراج کرده و برای مسئله بخش‌بندی پزشکی عملکرد به مراتب دقیق‌تری ارائه دهند.

◀ انتخاب الگوریتم یا معماری مناسب

برای وظایف بخش‌بندی تصاویر پزشکی، معماری‌های مبتنی بر U-Net به عنوان یک استاندارد شناخته می‌شوند. در این پروژه، با توجه به شواهد پژوهشی و نتایج گزارش شده در مقالات جدید، استفاده از معماری UNet++ پیشنهاد می‌شود. این معماری با بهره‌گیری از مسیرهای پرش متراکم (Dense Skip Connections)، Skip، معنایی میان ویژگی‌های لایه‌های رمزگذار و رمزگشا را کاهش می‌دهد و امکان ترکیب بهتر اطلاعات مکانی و معنایی را در سطوح مختلف فراهم می‌کند.



شکل ۱ - معماری UNet++ با مسیرهای پرش متراکم

استفاده از مدل‌های از پیش آموزش‌دیده یا مدل سفارشی

آموزش کامل مدل از صفر (From Scratch) در حوزه پزشکی، به دلیل محدودیت حجم داده‌های برچسب‌خورده، معمولاً انتخاب بهینه‌ای نیست. رویکرد مناسب‌تر، استفاده از یادگیری انتقالی (Transfer Learning) است. در این روش، یک شبکه از پیش آموزش‌دیده مانند ResNet یا EfficientNet به‌عنوان بخش استخراج‌کننده ویژگی (Encoder) (Backbone) در ساختار UNet++ به کار گرفته می‌شود و سپس وزن‌های آن متناسب با داده‌های تخصصی پروژه، مانند دیتاست LiTS، به‌صورت تنظیم ظریف (Fine-tuning) بهینه می‌گردد.

۷. گام هفتم: آموزش مدل

انتخاب تابع زیان (Loss Function)

در تصاویر CT، ناحیه تومور معمولاً نسبت بسیار کوچکی از کل تصویر را تشکیل می‌دهد؛ بنابراین با عدم تعادل شدید کلاس‌ها مواجه هستیم و توابع زیان کلاسیک به‌تنهایی عملکرد مناسبی ندارند. رویکرد رایج و مؤثر، استفاده از Dice Loss (برای بیشینه‌سازی همپوشانی ماسک پیش‌بینی‌شده و ماسک واقعی) در ترکیب با BCE (Binary Cross-Entropy) یا استفاده از Focal Loss برای تمرکز بیشتر روی نمونه‌های سخت و کلاس اقلیت است. ضریب دایس به صورت زیر تعریف می‌شود:

$$\text{Dice} = \frac{2|X \cap Y|}{|X| + |Y|}$$

که در آن X ماسک پیش‌بینی‌شده و Y ماسک Truth Ground است.

تنظیم ابرپارامترها (Hyperparameter Tuning)

به دلیل حجم بالای داده‌های سه‌بعدی NIfTI و سنگینی معماری UNet++ محدودیت حافظه GPU تعیین‌کننده است؛ بنابراین Batch Size معمولاً کوچک انتخاب می‌شود (حدود ۴ تا ۱۶). نرخ یادگیری (Learning Rate) اغلب با مقدار اولیه 10^{-4} شروع می‌شود و استفاده از زمان‌بند نرخ یادگیری (LR Scheduler) مانند ReduceLROnPlateau برای کاهش خودکار نرخ در صورت توقف بهبود، توصیه می‌گردد. به‌عنوان بهینه‌ساز نیز الگوریتم‌های Adam یا AdamW انتخاب‌های استاندارد و کارآمدی برای این نوع شبکه‌ها هستند.

پایش فرآیند آموزش و جلوگیری از بیش‌برازش (Overfitting Prevention)

به دلیل محدود بودن داده‌های برچسب‌خورده پزشکی، افزایش داده (Data Augmentation) نقش کلیدی در بهبود تعمیم‌پذیری دارد. اعمال تبدیلاتی مانند چرخش (Rotation)، قرینه‌سازی (Flipping) و به‌ویژه Elastic Deformation (برای شبیه‌سازی تغییرات طبیعی بافت‌های نرم) بسیار مؤثر است. علاوه بر این، استفاده از توقف زودهنگام (Early Stopping) ضروری است؛ به‌طوری که معیار Validation Dice Score به‌صورت پیوسته پایش شود و اگر برای مثال طی ۱۰ اپیاک متوالی بهبودی مشاهده نشد، آموزش

متوقف گردد تا از حفظیات روی داده‌های آموزش و افت عملکرد روی داده‌های جدید جلوگیری شود.

۸ گام هشتم: ارزیابی مدل

چرا معیار صحت عمومی (Accuracy) فریبنده است؟

در تصاویر Scan CT کبد، معمولاً تومورها بخش بسیار کوچکی (مثلاً کمتر از ۱٪) از کل حجم تصویر را اشغال می‌کنند. در چنین شرایطی با عدم تعادل شدید کلاس‌ها روبرو هستیم؛ به طوری که اگر مدل به طور ساده تمام پیکسل‌ها را پس‌زمینه پیش‌بینی کند، صحت عمومی سامانه ۹۹٪ ثبت خواهد شد، در حالی که مدل از لحاظ بالینی کاملاً بی‌ارزش است. به همین دلیل، ارزیابی مدل بر پایه معیارهای مبتنی بر هم‌پوشانی و سنجش فواصل مرزی انجام می‌گیرد.

معیارهای ارزیابی مناسب چیست؟

برای سنجش دقیق عملکرد مدل از شاخص‌های تخصصی زیر استفاده می‌شود:

- **ضریب دایس (Dice Score) و تقاطع روی اجتماع (IoU):** این دو معیار، میزان هم‌پوشانی هندسی ماسک پیش‌بینی‌شده (X) و ماسک واقعی (Y) را ارزیابی می‌کنند. فرمول شاخص IoU به صورت زیر تعریف می‌شود:

$$IoU = \frac{|X \cap Y|}{|X \cup Y|}$$

- **فاصله هاسدورف Distance (Hausdorff) - HD:** این معیار بیشینه فاصله میان مرزهای پیش‌بینی‌شده توسط مدل و مرزهای واقعی را بر حسب میلی‌متر محاسبه می‌کند. سنجش دقیق فاصله هاسدورف برای پزشکان و جراحان حیاتی است تا مطمئن شوند مدل مرز ضایعه را فراتر یا کمتر از حد واقعی تخمین نزده و در نتیجه در فرآیند درمان یا جراحی آسیبی به بافت‌های سالم مجاور وارد نمی‌شود.

تحلیل نتایج و شناسایی نقاط ضعف و قوت

ارزیابی نهایی روی مجموعه آزمون (Test Set) که در فرآیند آموزش کاملاً دست‌نخورده باقی مانده است، انجام می‌گیرد. در این مرحله، عملکرد مدل در بخش‌بندی کبد سالم (کلاس آسان‌تر به دلیل ابعاد بزرگ‌تر و مرزهای واضح‌تر) و تومورها (کلاس دشوارتر به

دلیل ابعاد متغیر و کنتراست پایین) به صورت مجزا تحلیل شده و چالش‌هایی نظیر خطای مدل در مواجهه با تومورهای بسیار کوچک یا موارد دارای آرتیفکت‌های شدید بررسی می‌گردند.

۹ ✨ گام نهم: بهبود و بهینه‌سازی

✧ جلوگیری از بیش‌برازش و حفظ‌کردن داده‌ها (Regularization)

شبکه‌های عصبی عمیق با پارامترهای بالا مستعد بیش‌برازش (Overfitting) هستند؛ به این معنا که به‌جای یادگیری الگوها و ویژگی‌های کلی تومور، داده‌های آموزشی را حفظ می‌کنند. جهت مقابله با این پدیده، از تکنیک‌های منظم‌سازی (Regularization) مانند Dropout استفاده می‌شود. در این روش، با خاموش کردن تصادفی درصدی از نرون‌ها در هر مرحله از آموزش، شبکه ناچار می‌شود مسیرهای موازی و ویژگی‌های قوی‌تری را برای تصمیم‌گیری پیدا کند و تعمیم‌پذیری آن به شکل چشمگیری افزایش یابد.

✧ تکنیک افزایش داده در زمان تست (TTA)

روش Test-Time Augmentation (TTA) برای افزایش پایداری و دقت پیش‌بینی مدل بر روی داده‌های آزمون اعمال می‌شود. در این تکنیک، هر تصویر ورودی جدید علاوه بر حالت اصلی، تحت چند تبدیل ساده و هندسی (مانند قرینه‌سازی افقی یا چرخش‌های جزئی) قرار گرفته و به مدل تغذیه می‌شود. در نهایت، پیش‌بینی نهایی از میانگین‌گیری یا تلفیق خروجی‌های به‌دست‌آمده از این زوایای مختلف حاصل می‌شود که این امر خطاهای موضعی مدل را کاهش می‌دهد.

✧ استفاده از خرد جمعی مدل‌ها (Ensemble Learning)

به منظور بهینه‌سازی نهایی و افزایش ضریب اطمینان بالینی، می‌توان از یادگیری جمعی (Ensemble) بهره برد. در این رویکرد، چندین معماری یا مدل مختلف که با استراتژی‌ها و بخش‌های متفاوتی از داده‌ها آموزش دیده‌اند، با یکدیگر ترکیب می‌شوند. در زمان استنتاج، خروجی تمام مدل‌ها برای یک تصویر مشخص محاسبه شده و با استفاده از روش‌هایی نظیر میانگین‌گیری وزن‌دار یا رای‌گیری پیکسلی، دقیق‌ترین ماسک نهایی تولید می‌شود که این کار ریسک خطای تک‌مدلی را به حداقل می‌رساند.

۱۰ 📌 گام دهم: اعتبارسنجی نهایی

◀ آیا مدل در شرایط واقعی عملکرد خوبی دارد؟

بر اساس نتایج بنچمارک‌های مرجع مانند LiTS و عملکرد معماری‌های پیشرفته‌ای نظیر UNet++، مدل‌های یادگیری عمیق در شرایط کنترل‌شده آزمایشگاهی به دقت‌های بالایی (مانند Dice Score بالای ۹۰٪ برای کبد و بین ۷۰ تا ۸۰٪ برای تومور) دست یافته‌اند. با این حال، انتقال مدل به محیط‌های بالینی واقعی نیازمند ارزیابی در شرایط عملیاتی است. به این منظور، سیستم در ابتدا به صورت موازی و در پس‌زمینه بیمارستان (Shadow Mode) مستقر می‌شود تا بدون اثرگذاری مستقیم بر فرآیند درمان، خروجی‌های آن با تصمیمات واقعی رادیولوژیست‌ها مقایسه و صحت‌گذاری شود.

◀ ارزیابی روی داده‌های دیده‌نشده (External Validation)

برای سنجش واقعی قدرت تعمیم‌پذیری، ارزیابی خارجی (External Validation) با استفاده از داده‌های بیمارستان‌ها و اسکنرهایی که در فرآیند آموزش مدل حضور نداشته‌اند، الزامی است. این گام تضمین می‌کند که مدل نسبت به نویزهای خاص، ضخامت مقاطع و پروتکل‌های تصویربرداری یک مرکز درمانی دچار بیش‌برازش نشده و عملکرد پایدار خود را در مواجهه با توزیع‌های داده‌ای جدید حفظ می‌کند.

◀ بررسی خطاهای بحرانی و ریسک‌های بالقوه

در سناریوهای تصویربرداری پزشکی، وزن خطاهای مختلف یکسان نیست. خطای منفی کاذب (False Negative) که به معنای عدم شناسایی و نادیده گرفتن تومور توسط مدل است، تهدیدی حیاتی برای جان بیمار به شمار می‌رود و بسیار خطرناک‌تر از خطای مثبت کاذب (False Positive) یا تشخیص اشتباه بافت سالم به عنوان تومور است. از این رو، ارزیابی نرخ منفی کاذب سیستم و مرزبندی‌های دقیق مرز ضایعات در سناریوهای دشوار بالینی، فاز کلیدی در تایید نهایی مدل خواهد بود.

۱۱ ⚙️ گام یازدهم: استقرار سیستم

انتخاب بستر مناسب استقرار (On-Premise) Deployment

برای کاربردی شدن مدل در محیط بالینی، باید آن را از فضای آزمایشگاهی (مانند نوتبوک‌های پایتون) خارج کرده و بدون ایجاد مزاحمت، در جریان کار روزمره پزشک قرار داد. در حوزه پزشکی به دلیل حساسیت بالای داده‌ها و قوانین سخت‌گیرانه حریم خصوصی، ارسال تصاویر بیماران به سرویس‌های ابری (Cloud) معمولاً منطقی یا حتی مجاز نیست. بنابراین، مدل بهینه‌شده روی سرورهای داخلی و امن بیمارستان (On-Premise) یا روی زیرساخت نزدیک به دستگاه تصویربرداری (Edge/On-site Server) مستقر می‌شود تا کنترل کامل امنیت، دسترسی و نگهداری داده‌ها حفظ گردد.

یکپارچه‌سازی با سیستم‌های موجود بیمارستان (Integration)

رادیولوژیست‌ها قرار نیست با کد، محیط‌های ناشناخته یا ابزارهای توسعه کار کنند؛ آن‌ها از سامانه‌های استاندارد مانند PACS (سیستم بایگانی و تبادل تصاویر پزشکی) برای مشاهده و گزارش‌نویسی استفاده می‌کنند. در نتیجه، سیستم سگمنتیشن باید به‌صورت یک جزء پنهان و قابل اطمینان به PACS متصل شود و خروجی را در قالب استانداردهای پزشکی (مانند DICOM و RTSTRUCT/DICOM-SEG در صورت نیاز) تحویل دهد. این یکپارچه‌سازی تضمین می‌کند که پزشک خروجی مدل را در همان محیط کاری معمول خود و به‌صورت یک لایه Overlay روی تصویر مشاهده کند.

توسعه API و بسته‌بندی سرویس (API & Dockerization)

برای ارائه مدل به‌عنوان یک سرویس پایدار، تکرارپذیر و قابل استقرار در شبکه بیمارستان، مدل نهایی به همراه تمام پیش‌نیازها (پیش‌پردازش، پس‌پردازش و وابستگی‌ها) در قالب یک کانتینر مانند Docker بسته‌بندی می‌شود. سپس از طریق یک وب‌سرویس (برای مثال با FastAPI) یک API داخلی فراهم می‌گردد تا سامانه‌های بیمارستانی بتوانند تصاویر را ارسال کرده و خروجی سگمنتیشن را دریافت کنند. این رویکرد، استقرار و به‌روزرسانی نسخه‌های مختلف مدل را ساده‌تر و کنترل‌پذیرتر می‌کند.

جریان کار عملیاتی (Workflow) در دنیای واقعی

در سناریوی واقعی، روند پیشنهادی به شکل زیر است: CT Scan بیمار گرفته می‌شود → تصویر به صورت خودکار به API مدل ارسال می‌گردد → مدل در زمان کوتاه (نزدیک به بلادرنگ) کبد/تومور را سگمنت می‌کند → ماسک خروجی (یا ساختار سگمنتیشن استاندارد) به PACS بازگردانده می‌شود → پزشک هنگام مشاهده پرونده بیمار، ناحیه پیشنهادی مدل را به صورت یک Overlay رنگی روی تصویر می‌بیند و تصمیم نهایی و مسئولیت بالینی را بر عهده می‌گیرد.

۱۲ گام دوازدهم: پایش و مانیتورینگ

◀ پایش عملکرد در دنیای واقعی (Model Monitoring)

پس از استقرار سیستم، ارزیابی مستمر دقت مدل در مواجهه با بیماران جدید با ویژگی‌های بالینی و سنی متفاوت ضروری است. این کار از طریق پایش غیرفعال و دریافت بازخوردهای اصلاحی مستقیم از رادیولوژیست‌ها (به‌عنوان مثال، ثبت میزان اصلاح دستی ماسک پیشنهادی مدل توسط پزشک در سامانه PACS) انجام می‌شود تا هرگونه افت کارایی مدل در بلندمدت شناسایی شود.

◀ بررسی مداوم کیفیت داده‌های ورودی (Data Drift & Shift)

تغییر سخت‌افزار اسکنرها، اعمال پروتکل‌های جدید تصویربرداری یا تغییر غلظت ماده حاجب، توزیع داده‌های ورودی را نسبت به داده‌های زمان آموزش تغییر می‌دهد (Data Drift). سیستم مانیتورینگ باید به‌صورت خودکار شاخص‌های آماری تصاویر جدید را رصد کرده و در صورت بروز انحراف جدی از الگوی داده‌های اولیه، به تیم فنی هشدار دهد تا از تحلیل نادرست تصاویر جلوگیری شود.

◀ ثبت و تحلیل خطاها و هشدارها (Alerting & Logging)

تمام تراکنش‌ها، فراداده‌های تصاویر ورودی، نتایج پیش‌بینی و زمان پردازش مدل باید در بستری امن ثبت (Log) شوند. در صورت بروز هرگونه مشکل سیستمی مانند افزایش زمان استنتاج، خطاهای خارج از محدوده حافظه پردازنده گرافیکی یا توقف ناگهانی سرویس، مکانیزم‌های هشداردهی باید بلافاصله فعال شده و تیم پشتیبانی فنی را مطلع سازند.

۱۳ ↑ گام سیزدهم: بازآموزی و بروزرسانی

◀ معیارها و زمان نیاز به بازآموزی مدل

نیاز به بازآموزی مدل زمانی قطعی می‌شود که شاخص‌های مانیتورینگ نشان‌دهنده افت کارایی مداوم باشند، خطاهای سیستماتیک در گزارش‌های پزشکان ثبت شود، یا اسکنرهای جدیدی در بیمارستان راه‌اندازی شوند که خروجی متفاوتی دارند. در این شرایط، چرخه‌ی آموزش مجدد مدل فعال می‌گردد.

◀ به‌روزرسانی داده‌ها و یادگیری فعال (Active Learning)

تصاویری که مدل در دنیای واقعی در پردازش آن‌ها دچار خطا شده (مانند تشخیص اشتباه کیست‌ها به جای تومور) پس از اصلاح دستی توسط رادیولوژیست، به‌عنوان داده‌های ارزشمند به پایگاه داده آموزشی اضافه می‌شوند. با تمرکز بر روی نمونه‌های چالش‌برانگیز و سخت (Hard Negative Mining)، مدل جدید با کارایی بالاتر و با استفاده از منابع پردازشی کمتر بازآموزی می‌شود.

◀ مدیریت نسخه‌ها و عقب‌گرد مدل (Rollback) & Versioning

نسخه‌های جدید مدل نباید مستقیماً جایگزین نسخه در حال خدمت شوند. با استفاده از سیستم‌های مدیریت مدل (مانند MLflow)، هر نسخه شناسنامه و تاریخچه مشخصی دارد. پس از آموزش، نسخه جدید به‌صورت تدریجی مستقر شده و در صورت بروز هرگونه رفتار پیش‌بینی‌نشده بالینی، سیستم بلافاصله به نسخه پایدار قبلی عقب‌گرد (Rollback) داده می‌شود.

۱۴ گام چهاردهم: ملاحظات اخلاقی و قانونی

◀ حریم خصوصی کاربران و امنیت داده‌ها

تصاویر پزشکی به شدت حساس هستند و امنیت آن‌ها باید با استانداردهایی نظیر HIPAA و GDPR مطابقت داشته باشد. فرآیند بی‌نام‌سازی داده‌ها (De-identification) و حذف اطلاعات هویتی (PHI) از متادیتای فایل‌های DICOM باید پیش از ارسال تصویر به وب‌سرویس و در مبدأ انجام شود تا حریم خصوصی بیماران در تمامی مراحل حفظ گردد.

◀ شفافیت تصمیم‌گیری و کاهش سوگیری‌ها

جعبه سیاه بودن مدل‌های یادگیری عمیق یک چالش جدی در پزشکی است؛ بنابراین استفاده از ابزارهای هوش مصنوعی قابل تفسیر (XAI) برای نمایش معیارهای تصمیم‌گیری مدل اهمیت بالایی دارد. علاوه بر این، ارزیابی مدل روی داده‌های توزیع‌های مختلف تضمین می‌کند که سیستم دچار سوگیری (Bias) نژادی، جنسیتی یا سنی نشده و عدالت بالینی را رعایت می‌کند.

◀ مسئولیت‌پذیری در قبال خطاها و پیامدها

از نظر حقوقی، سیستم‌های هوش مصنوعی تشخیصی در حال حاضر به‌عنوان سیستم‌های پشتیبان تصمیم‌گیری (Decision Support Systems) طبقه‌بندی می‌شوند. در سناریوی بروز خطای منفی کاذب (False Negative) که به بیمار آسیب جدی می‌رساند، ابزار هوش مصنوعی سلب مسئولیت شده و مسئولیت نهایی تایید یا رد گزارش‌ها و تشخیص نهایی همواره بر عهده پزشک متخصص خواهد بود.

۱۵ منابع

- [1] J. Wang, et al. *A deep-learning approach for segmentation of liver tumors in magnetic resonance imaging using UNet++*. BMC Cancer 23(1), 1060 (2023). PMC - PubMed.
- [2] P. Bilic, et al. *The Liver Tumor Segmentation Benchmark (LiTS)*. Medical Image Analysis 84, 102680 (2023).