

دوره آفلاین یادگیری ماشین های نظارت شده

دوره آموزشی: یادگیری ماشین نظارت شده
تاریخ گزارش: ۲۸ خرداد تا ۲۳ تیر ۱۴۰۴

👤 **مدرس:** جناب آقای احسان ناظر فرد

👤 **نگارنده:** سیدعرفان مسعودی

@erfanmasoudiba 📍

erfanmasoudiba@gmail.com ✉

linkedin.com/in/erfan-masoudi 🌐 github.com/ErfanMasoudiBA 🐙

فهرست مطالب

۲	۱ تمرین اول: پیش‌بینی فروش فیلم (CSM Dataset)
۶	۲ تمرین دوم: پیش‌بینی بارش (BOM Dataset)
۸	۳ تمرین سوم: تشخیص بدافزار (Anti Malware Dataset)
۱۰	۴ تمرین چهارم: تشخیص چهره (Olivetti Faces)

۱ تمرین اول: پیش‌بینی فروش فیلم (CSM Dataset) با رگرسیون خطی

هدف و ساختار کلی آزمایش

هدف این تمرین، پیش‌بینی میزان فروش ناخالص فیلم‌ها (Gross) است. برای درک عمیق‌تر اثر فرآوری داده‌ها، کل فرآیند را به دو رویکرد کاملاً متفاوت تقسیم کرده و نتایج آن‌ها را به چالش کشیده‌ایم:

۱. رویکرد اول: ساده‌سازی داده‌ها و پیاده‌سازی ریاضی الگوریتم‌ها از پایه.
۲. رویکرد دوم: غنی‌سازی هوشمند داده‌ها (مهندسی ویژگی) و استفاده از پتانسیل کامل ویژگی‌ها.

رویکرد اول: تقلیل ابعاد و پیش‌پردازش داده‌ها

در این فاز، تمرکز روی پیاده‌سازی دست‌نویس الگوهای ریاضی و کاهش ابعاد داده بود.

- تحلیل اکتشافی داده‌ها (EDA): با بررسی ماتریس همبستگی، متغیرهای متنی و هم‌خط مثل Likes, Comments, Views, Dislikes شناسایی شدند. در مقابل، سه متغیر Budget، Screens و Sequel بیشترین همبستگی را با فروش داشتند.
- انتخاب ویژگی (Feature Selection): در این گام فقط ۳ متغیر کلیدی فوق حفظ و باقی ستون‌ها حذف شدند.
- مدیریت داده‌های گمشده: مقادیر خالی در ستون‌های بودجه و سینماها با الگوریتم KNNImputer (با $k = 5$) به صورت هوشمند پر شد.
- تعدیل مقیاس و نرمال‌سازی: به دلیل نوسان بالا، تبدیل لگاریتمی $\log(1+x)$ روی ویژگی‌های مالی اعمال شد و با روش Min-Max به بازه $[0, 1]$ منتقل شدند.

مدل‌سازی و ساختار ریاضی فرآیند

سه مکانیزم برای یافتن بردار وزن بهینه (θ) پیاده‌سازی و مقایسه شد:


- **کاهش گرادیان سنتی (Gradient Descent):** با نرخ یادگیری $\alpha = 0.01$ روی تابع هزینه مربعات خطا.

- **بهینه‌سازی با منظم‌سازی L2 (Ridge):** جهت کنترل وزن‌ها با جریمه $\lambda = 1/0$ (بدون اثر روی وزن بایاس):

$$J(\theta) = \frac{1}{2m} \left(\sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 + \lambda \sum_{j=1}^n \theta_j^2 \right)$$

- **معادله نرمال (Normal Equation):** محاسبه تحلیلی و دقیق وزن‌ها برای ارزیابی صحت گرادیان کاهش:

$$\theta = (X^T X)^{-1} X^T y$$



شکل ۱: ماتریس همبستگی متغیرهای منتخب با متغیر هدف (Gross)

نتایج عددی رویکرد اول و چالش بیش‌برازش

مقایسه مقدار نهایی تابع هزینه نشان‌دهنده همگرایی دقیق کد دست‌نویس با فرمول تحلیلی است:

• هزینه کاهش گرادیان دست‌نویس: ۲/۱۷۹

• هزینه تحلیلی معادله نرمال: ۲/۰۸۰ (بهینه مطلق)

• هزینه رگرسیون ریج (L2): ۲/۸۰۳

معیارهای ارزیابی مدل اولیه روی داده‌های تست به شرح زیر است:

$$MSE = ۴/۳۲۷ \quad | \quad RMSE = ۲/۰۸۰ \quad | \quad R^2 = ۰/۴۲۷$$

برای بهبود این رویه، رگرسیون چندجمله‌ای (Polynomial) در درجات مختلف ارزیابی شد. همان‌طور که در جدول زیر مشهود است، افزایش درجه مدل به شدت باعث بروز وضعیت بیش‌برازش (Overfitting) شده است:

جدول ۱: تحلیل خطای رگرسیون چندجمله‌ای به ازای درجات مختلف			
درجه (d)	خطای آموزش (MSE)	خطای آزمون (MSE)	وضعیت مدل
d = ۱	۳/۰۴۷	۴/۳۵۹	پایدار / خطای بالا
d = ۲	۳/۱۱۸	۴/۳۵۵	بهینه نسبی
d = ۳	۳/۳۰۹	۴/۵۵۸	آغاز بیش‌برازش
d = ۴	۳/۴۵۳	۴/۷۳۲	بیش‌برازش شدید
d = ۵	۳/۵۲۰	۴/۸۲۷	شکست مدل

➤ رویکرد دوم: مهندسی ویژگی پیشرفته

در فاز دوم، استراتژی تغییر کرد؛ هیچ داده‌ای دور ریخته نشد و تلاش بر غنی‌سازی متغیرها قرار گرفت.

• **نشانگر باینری برای داده‌های گم‌شده:** به جای پر کردن ساده با میانه، ستون‌های

کمکی مثل Budget_is_missing ساخته شد تا خود «فقدان داده» به یک ویژگی یادگرفتنی تبدیل شود و مقادیر اصلی با میانه پر شدند.

• **تحلیل احساسات نام فیلم (NLP):** نام متنی فیلم‌ها (Movie) با کتابخانه

vaderSentiment پردازش شد و بار روانی و مثبت/منفی بودن عنوان فیلم به یک معیار عددی پیوسته بین -۱ تا +۱ تبدیل و به مدل تزریق گردید.

◀ نتایج مدل های غنی شده

پس از استانداردسازی داده ها با MinMaxScaler، نتایج به شکل چشم گیری بهبود یافت:

- **مدل SGDRegressor:** تنها پس از ۲۳ تکرار با میانگین زیان بسیار پایین ۰/۰۱۲ همگرا شد و به دقت $R^2 = ۰/۴۷۹$ رسید.
- **مدل رگرسیون خطی استاندارد:** با بهره گیری از داده های غنی شده، جهش بزرگی در عملکرد ثبت کرد و به معیارهای زیر دست یافت:

$$MSE = ۲,۷۷۳ \quad | \quad RMSE = ۱,۶۶۵ \quad | \quad R^2 = ۰/۶۱۳$$

◀ تحلیل، نتیجه گیری و سوال تحلیلی

خطای نهایی مدل (MSE) از ۴/۳۲۷ به ۲/۷۷۳ کاهش یافت و ضریب تعیین (R^2) از ۴۲% به ۶۱% ارتقا پیدا کرد. این جهش ثابت می کند که در مسائل رگرسیون، **غنی سازی داده ها (مهندسی ویژگی)** بسیار موثرتر و پایدارتر از پیچیده سازی فرمول های ریاضی عمل می کند.

سوال: آیا می توانیم نام فیلم را از مجموعه داده حذف کنیم؟ چرا؟

پاسخ: در رگرسیون خطی سنتی، **بله**؛ چون مدل های رگرسیونی فرمول خطی دارند و رشته های متنی خام را نمی فهمند. اما از نظر مهندسی ویژگی، **خیر**؛ دور ریختن کامل نام فیلم اتلاف اطلاعات است. راهکار اصولی این است که مانند رویکرد دوم، ابتدا اطلاعات معنایی یا حسی آن را استخراج کرده (تبدیل به عدد) و سپس فرمت متنی خام را پاک کنیم.

۲ ☁ تمرین دوم: پیش‌بینی بارش با KNN


◀ پیش‌پردازش داده‌ها (Preprocessing)

مراحل پیش‌پردازش روی مجموعه داده BOM به صورت یکپارچه با ابزار Pipeline پیاده‌سازی شد:

- **رمزگذاری ویژگی‌های چرخه‌ای:** استخراج ماه و روز هفته از تاریخ و همچنین جهت وزش باد، و تبدیل آن‌ها به مولفه‌های سینوسی و کسینوسی برای حفظ کامل خاصیت دوره‌ای زمان و جهت.
- **استخراج ویژگی‌های مکانی:** جایگزینی نام متنی شهرها با مختصات جغرافیایی دقیق طول و عرض (Latitude / Longitude).
- **مدیریت داده‌های گمشده (Imputation):** متغیرها بر اساس درصد مقادیر از دست‌رفته گروه‌بندی شدند: برای کمتر از ۵٪ از میانه، بین ۵٪ تا ۳۰٪ از الگوریتم KNNImputer (با $k = 5$)، و برای مقادیر بیش از ۳۰٪ از میانه به همراه یک متغیر نشانگر (Indicator) استفاده شد.

◀ آموزش مدل و تنظیم پارامترها

الگوریتم K-Nearest Neighbors روی داده‌های مقیاس‌شده با StandardScaler برای مقادیر مختلف $k \in \{1, 2, 3, 5, 9, 15, 21, 31\}$ ارزیابی شد. برای افزایش سرعت اجرا و بهینه‌سازی محاسباتی، فواصل یک‌بار برای ماکزیمم مقدار k محاسبه گردید.



شکل ۲: تغییرات معیار $F1$ -score به ازای مقادیر مختلف k . بهترین عملکرد در $k = 2$ با امتیاز ۰/۵۸۲ حاصل شده است.

◀ تحلیل عملکرد مدل بر اساس نمودار

همان طور که در نمودار ۲ مشخص است، مدل با $k = ۲$ بالاترین معیار F1-score را برای تشخیص کلاس هدف (بارش) ثبت کرده است. مقادیر بالاتر k به دلیل افزایش نرمی مرزهای تصمیم گیری، باعث افت شدید حساسیت مدل (Recall) در شناسایی کلاس اقلیت شده اند.

◀ پاسخ به سوال تحلیلی (سیستم های بلادرنگ)

سوال: برای یک سیستم پیش بینی بلادرنگ (Real-time)، کدام الگوریتم انتخاب بهتری است؟

پاسخ: الگوریتم **درخت تصمیم** (Decision Tree) انتخاب بسیار بهتری نسبت به KNN است. دلیل این امر این است که KNN یک یادگیرنده تنبل (Lazy Learner) است و در فاز تست (آزمون)، باید فاصله داده جدید را با تک تک نمونه های آموزشی محاسبه کند که زمان اجرای آن متناسب با پیچیدگی زیر است و به شدت کند می شود:

$$\mathcal{O}(n \times d)$$

در مقابل، درخت تصمیم یک یادگیرنده مشتاق (Eager Learner) است و پس از آموزش، زمان پیش بینی آن تنها متناسب با عمق درخت بوده و از مرتبه بسیار سریع زیر خواهد بود که سرعت فوق العاده بالایی در سیستم های عملیاتی دارد:

$$\mathcal{O}(\log n)$$


۳ تمرین سوم: تشخیص بدافزار

هدف و فرآیند آماده‌سازی داده‌ها

هدف این تمرین، شناسایی بدافزارها از روی ویژگی‌های ساختاری فایل‌ها بر اساس ستون هدف OUTPUT است. داده‌ها پس از اطمینان از عدم وجود مقادیر گم‌شده (Null) و عددی بودن تمام ویژگی‌ها، به نسبت ۸۰٪ آموزش و ۲۰٪ آزمون تقسیم شده و با StandardScaler مقیاس‌گذاری شدند.

مدل رگرسیون لجستیک (Logistic Regression)


یک مدل رگرسیون لجستیک با تنظیم حداکثر ۱۰۰۰ تکرار ($\text{max_iter}=1000$) جهت تضمین همگرایی آموزش داده شد. این مدل عملکرد فوق‌العاده‌ای با دقت حدود ۹۵٪ روی داده‌های آزمون ثبت کرد.



شکل ۳: ماتریس درهم‌ریختگی مدل رگرسیون لجستیک؛ نرخ خطای بسیار پایین در شناسایی فایل‌های مخرب.

مدل نایو بیز گوسی (Gaussian Naive Bayes)

در این فاز، مدل دسته‌بند بیز ساده (GaussianNB) روی همان داده‌های مقیاس‌شده اعمال گردید. معیار عملکردی این مدل افت شدیدی را تجربه کرد و دقت آن به حدود ۶۸٪ کاهش یافت.



شکل ۴: ماتریس درهم‌ریختگی مدل نایو بیز؛ ناتوانی آشکار مدل در فیلتر کردن فایل‌های مخرب.

تحلیل و مقایسه عملکرد دو مدل بر اساس ماتریس درهم‌ریختگی

با تحلیل و مقایسه ماتریس‌های درهم‌ریختگی فوق، مدل رگرسیون لجستیک عملکردی به مراتب برتر و پایدارتر نشان می‌دهد. دلایل این برتری ملموس عبارتند از:

- **کنترل فاجعه‌ی منفی کاذب (False Negative):** در مسائل امنیت سایبری و بدافزار، ورود یک بدافزار به سیستم (منفی کاذب) بسیار خطرناک‌تر از مسدود شدن اشتباه یک فایل امن (مثبت کاذب) است. مدل رگرسیون لجستیک تنها ۵۳ بدافزار را از دست داده، در حالی که نایو بیز ۷۰۱ بدافزار (یک فاجعه امنیتی) را به اشتباه امن تشخیص داده است.

- **تحلیل مثبت کاذب (False Positive):** با اینکه نرخ مثبت کاذب نایو بیز کمی کمتر است (۱۰ در برابر ۵۴)، اما در حضور خطای هولناک ستون بدافزارهای فرار کرده، این معیار کاملاً ارزش خود را از دست می‌دهد.

- **علت ریاضی شکست نایو بیز:** الگوریتم نایو بیز فرض را بر استقلال کامل ویژگی‌ها از یکدیگر می‌گذارد. در داده‌های مربوط به بدافزارها، ویژگی‌های ساختاری فایل شدیداً به هم وابسته و هم‌بسته هستند. رگرسیون لجستیک با یادگیری دقیق وزن روابط فیچرها، این فرض محدودکننده را ندارد و به خوبی مرز تصمیم‌گیری را پیدا می‌کند.

۴ تمرین چهارم: تشخیص چهره (Olivetti Faces)

خلاصه پیاده‌سازی و مصورسازی مجموعه داده

در این تمرین، مجموعه داده چهره‌های Olivetti شامل ۴۰ فرد متمایز (مجموعاً ۴۰۰ تصویر گریس‌کیل 64×64) با نسبت ۸۰-۲۰ به داده‌های آموزش و آزمون تقسیم شد. جهت بررسی ساختاری و تنوع چهره‌ها، تصویر اولین نمونه از هر ۴۰ شخص استخراج و در یک ساختار منظم مصورسازی شد:



شکل ۵: گرید تصاویر چهره‌های ۴۰ فرد متمایز در مجموعه داده Faces Olivetti

ارزیابی و مقایسه مدل‌های کلاسیک

عملکرد سه مدل یادگیری ماشین روی فضای ویژگی اصلی (ابعاد خام ۴۰۹۶ پیکسلی) مورد ارزیابی قرار گرفت. نتایج دقت به دست آمده روی داده‌های تست به شرح زیر است:

- ماشین بردار پشتیبان (SVM) با کرنل RBF: به دقت فوق‌العاده ۹۶/۲۵٪ دست یافت. این مدل به دلیل توانایی بالا در نگاشت داده‌های با ابعاد بالا به فضایی با تفکیک‌پذیری بهتر، بهترین عملکرد را نشان داد.
- جنگل تصادفی (Random Forest): به دقت پایدار ۹۵/۰٪ رسید که نشان‌دهنده قدرت بالای انسمبل‌های بگینگ در مدیریت نویزهای پیکسلی است.
- الگوریتم AdaBoost: به دقت بسیار ضعیف ۱۶/۲۵٪ سقوط کرد که نشان‌دهنده پدیده کم‌برازش (Underfitting) شدید است.

➤ ریشه‌یابی ضعف AdaBoost و بهبود آن با PCA و درخت‌های عمیق‌تر

دلیل افت شدید عملکرد AdaBoost خام دو مسئله بود: اول ابعاد بسیار بالای داده‌ها (۴۰۹۶ پیکسل) که مدل بوستینگ را گیج می‌کند، و دوم استفاده پیش‌فرض از درخت‌های با عمق ۱ (Decision Stumps) که برای تفکیک ۴۰ کلاس پیچیده چهره کاملاً ناتوان هستند. برای حل این مشکل، دو گام اساسی در کد پیاده‌سازی شد:

۱. **کاهش ابعاد با PCA:** ابعاد ویژگی‌ها از ۴۰۹۶ به ۱۵۰ مولفه اصلی بهینه‌شده کاهش داده شد تا نویز برطرف شده و فضا فشرده شود.

۲. **افزایش عمق مدل‌های پایه:** درخت تصمیم پایه‌ی AdaBoost از عمق ۱ به عمق ۳ ارتقا یافت تا توانایی یادگیری مرزهای غیرخطی را پیدا کند.

۵۷/۵٪ به ۱۶/۲۵٪ جهش چشمگیر دقت مدل AdaBoost از **نتیجه بهبود:**

➤ راهکارهای پیشنهادی برای ارتقای بیشتر نتایج

برای رساندن دقت مدل‌ها به مرز ۱۰۰٪، راهکارهای زیر به عنوان فازهای توسعه آتی پیشنهاد می‌گردند:

- **تنظیم ابرپارامترها (Hyperparameter Tuning):** اعمال فرآیند GridSearchCV بر روی عمق درخت‌های انسمبل، تعداد تخمین‌زننده‌ها و نرخ یادگیری (Learn-Rate) در الگوریتم بوستینگ.
- **افزایش داده‌ها (Data Augmentation):** با توجه به اینکه از هر فرد تنها ۱۰ تصویر در دسترس است، مدل‌ها مستعد بیش‌برازش هستند. اعمال تغییرات جزئی نظیر چرخش‌های کم، زوم و تغییرات روشنایی روی تصاویر آموزشی می‌تواند پایداری مدل را تضمین کند.
- **بهره‌گیری از یادگیری عمیق (CNN):** استفاده از شبکه‌های عصبی پیچشی به دلیل توانایی ذاتی در استخراج ویژگی‌های سلسله‌مراتبی و حفظ همبستگی فضایی پیکسل‌ها، گزینه‌ای بی‌نقص برای این سطح از تشخیص چهره است.